


P10.S8.01 : Le Machine Learning au service de Maintenance Prédicative (le cas des éoliennes)



CentraleSupélec



MathWorks®

Equipe :

Diego Ruiz Ponsoda
Ben Silva
Valentin Gérard
Ayoub Ennajah
Mohammed Ahlal

Encadrants :

Wassila Ouerdane (CentraleSupélec)
Jean-Philippe Poli (CentraleSupélec)
Lama Itani (MathWorks)

Contents

Equipe :	1
Encadrants :	1
Sommaire :	2
Introduction :	2
État de l'art :	2
A systematic literature review of machine learning methods applied to predictive maintenance	2
• Surveillance des matériels	4
Predictive maintenance with Matlab.....	5
Définition de RUL et les différents modèles pour l'estimer	6
Description de travail réalisé	7
Prétraitement des données:	7
Feature extraction :	8
Indicateur de Condition :	9
Modèle de Dégradation:	10
Résultats et prochaines étapes	11
Répartition des tâches	12

Sommaire :

#someone add context of the problem

Introduction :

#add information about the dataset such as format of data, plots of raw data, deliverables

État de l'art :

A systematic literature review of machine learning methods applied to predictive maintenance

Cet article commence par rappeler les différentes terminologies et approches générales des procédures de maintenance. En bref, on distingue :

- Run-to-Failure (R2F) : On répare les pièces au moment où elles cassent.
- Maintenance préventive : Les casses passées on permis de mettre au point une estimation de la durée de vie de chaque pièce de la machine. Cela permet de construire un planning de maintenance, les pièces sont alors en théorie changées avant la casse. Les problèmes de cette méthode viennent du fait qu'on va être amené dans certains cas à changer certaines pièces encore fonctionnelles ou à l'inverse se faire surprendre par les casses précoces.
- Maintenance prédictive : Ici, on utilise des capteurs qui mesurent certains signaux représentatifs de l'état des pièces et on déclenche l'opération de maintenance à partir du moment où leur dégradation est trop importante. L'avantage de cette procédure est qu'on optimise au maximum le nombre d'opérations et le temps de vie de chaque pièces.

La maintenance prédictive elle-même se sépare en différentes familles en fonction du modèle utilisé pour faire les prédictions :

- Approche par modèle : requière des connaissances mécaniques sur le système afin de le modéliser par des équations.
- Approche statistique : requière des connaissances mathématiques.
- Approche par intelligence artificielle : La plus prometteuse actuellement, d'après l'article, elle commence déjà à avoir des résultats supérieurs aux deux autres approches.

Cet article a pour but de faire un état de l'art des différentes méthodes de machine learning utilisées pour la maintenance prédictive.

- Le random forest (RF) est utilisé et a de bonnes performances lorsque le nombre de data est très inférieur au nombre d'échantillons (ce qui est notre cas dans ce projet). Il permet de faire de la classification et de la régression (donc est capable d'estimer le temps de vie restant). L'article nous redirige vers différents papiers qui ont réalisés de la maintenance prédictive avec un algorithme de RF (les résultats atteignent 85% de précision dans des cas réels). Finalement, l'article mentionne le fait que bien qu'il fut le modèle le plus utilisé, le RF souffre de problèmes de temps de calcul important.
- Les Artificial neural networks (ANN) ont des performances impressionnantes en comparaison aux RF. Ils ont notamment déjà été utilisés dans le cadre des turbines d'éoliennes avec des résultats de 92.6% en classification.
- Les Support Vectors Machine SVM sont utilisés a priori pour la classification mais l'article mentionne des modifications capables de lui faire effectuer une régression (voir Support Regression Vector SVR).
- L'article mentionne enfin les algorithmes K-means mais comme ces derniers ne sont pas capable de faire de la régression, nous ne les mentionnerons pas ici.

Pour conclure, cet article nous a permis de définir les différents algorithmes que nous pourrions mettre en place pour ce projet à savoir un RF, un ANN ou un SVR. Ici, on privilégiera les ANN car la littérature nous indique qu'ils ont déjà été utilisé par le passé pour effectuer des tâches très semblables à la notre (cf Biswal and Sabareesh, 2015 Design and development of a wind turbine test rig for condition monitoring studies).

Surveillance vibratoire et maintenance prédictive

Enjeux de la maintenance - some of this should be in introduction/context, not bibliography

- **Maintenance**

Même dans des conditions normales, le fonctionnement d'une installation entraîne un vieillissement des équipements et parfois des incidents. Afin d'assurer une exploitation correcte, il est essentiel de maintenir l'installation en bon état.

La maintenance a un coût, et il est crucial de trouver l'équilibre optimal pour maintenir l'installation à un coût minimal sans compromettre la sécurité des personnes. Comme le montre **la figure 1**, sans maintenance adéquate, le nombre d'incidents et leur coût augmenteront. À l'inverse, avec trop de maintenance préventive, le coût total augmentera également.

La maintenance optimale est donc un mélange harmonieux d'entretien préventif systématique et d'entretien correctif.




Figure 1 - Coût en fonction de la politique de maintenance exploitée

- **Surveillance des matériels**

La surveillance des équipements permet de réduire le niveau d'entretien préventif sans prendre de risques supplémentaires, car on s'assure toujours que le matériel ne présente pas d'anomalie. Par conséquent, les coûts peuvent être réduits si le coût de la surveillance reste limité. La surveillance s'intègre dans la stratégie de maintenance et doit assurer **la prévention** des risques majeurs (arrêt des machines lorsque les conditions de sécurité pour l'homme ou la machine ne sont pas respectées), **la détection** précoce des anomalies pour minimiser les dommages en remplaçant les composants défectueux si possible avant l'incident et au meilleur moment, et **l'analyse après incident** pour remédier aux défauts constatés, éviter leur réapparition à l'avenir ou définir les modifications nécessaires.

- **Vibration : un bon indicateur d'état**

Le fonctionnement des machines génère des forces qui seront souvent à l'origine des défaillances ultérieures (forces tournantes, turbulences, chocs, instabilité). Ces forces provoquent à

leur tour des vibrations qui endommagent les structures et les composants des machines. L'analyse de ces vibrations permet d'identifier les forces dès leur apparition, avant qu'elles n'aient causé des dommages irréversibles. Elle permet également, après analyse, d'en déterminer l'origine et d'estimer les risques de défaillance. **La maintenance prédictive repose sur ces concepts. Pour la mettre en œuvre, il est nécessaire de déterminer les causes de défaillance les plus fréquentes, d'évaluer leurs coûts et leur probabilité d'apparition, et de mettre en place une politique permettant de détecter le plus tôt possible les symptômes.**

- **Reconnaître les défauts**


La maintenance prédictive nécessite un diagnostic minimal des défauts et de leur gravité. La première étape d'une action de surveillance consiste donc à déterminer les défauts susceptibles de survenir sur la machine à surveiller. La seconde étape concerne les manifestations de ces défauts. Il est important de déterminer et de mesurer les informations et les paramètres descripteurs du défaut pour disposer des informations appropriées. Celles-ci permettront de déterminer si la situation est normale ou non (détection d'anomalie) et d'identifier ultérieurement l'origine et la gravité des anomalies (diagnostic de l'origine et de la gravité des anomalies).

La maintenance prédictive dépend de la capacité à reconnaître et à diagnostiquer les défauts et leur gravité. Ainsi, la première étape d'une action de surveillance consiste à identifier les problèmes potentiels susceptibles de survenir sur la machine en question. La seconde étape porte sur la manière dont ces défauts se manifestent. Il est essentiel de déterminer et de mesurer les informations et les paramètres décrivant le défaut afin d'obtenir les bonnes informations. Ces informations permettront non seulement de déterminer si la situation est normale ou non (détection d'anomalies), mais aussi d'identifier ultérieurement la cause et la gravité des anomalies détectées (diagnostic de l'origine et de la gravité des anomalies).

En somme, la maintenance optimale consiste en un mélange équilibré d'entretien préventif systématique et d'entretien correctif, soutenu par la surveillance et l'analyse des équipements. La maintenance prédictive s'appuie sur l'analyse des vibrations et l'identification des défauts pour minimiser les risques de défaillance et réduire les coûts globaux. Cette approche nécessite une compréhension approfondie des machines et des défauts potentiels, ainsi qu'une stratégie de surveillance bien conçue pour assurer une gestion efficace et rentable des équipements.

Predictive maintenance with Matlab


Ce livre électronique fournit par le client est une méthode pratique permettant d'implémenter à l'aide de Matlab un modèle de maintenance prédictive. Après avoir brièvement décrit l'intérêt de la maintenance prédictive, il identifie le workflow classique d'un projet d'implémentation de maintenance prédictive à travers le schéma suivant :



Pour ce projet, en accord avec le client, nous n'effectuerons que les tâches 3 et 4, c'est pourquoi je ne détaillerais que ces dernières.

Définition de RUL et les différents modèles pour l'estimer

La "remaining useful life" (RUL) est une mesure du temps restant avant qu'un objet ne cesse de fonctionner ou ne nécessite une maintenance importante, on l'utilise dans le contexte de la maintenance prédictive. En utilisant les données sur la performance passée d'un objet, on peut prédire combien de temps il peut encore fonctionner avant de tomber en panne ou d'avoir besoin d'une maintenance.



Les modèles de prédiction de la RUL peuvent être classés en trois catégories principales : les modèles de similarité, les modèles de survie et les modèles de dégradation. Chacun de ces modèles est utilisé pour estimer la RUL d'un objet en utilisant différentes sources de données et en utilisant des approches différentes.

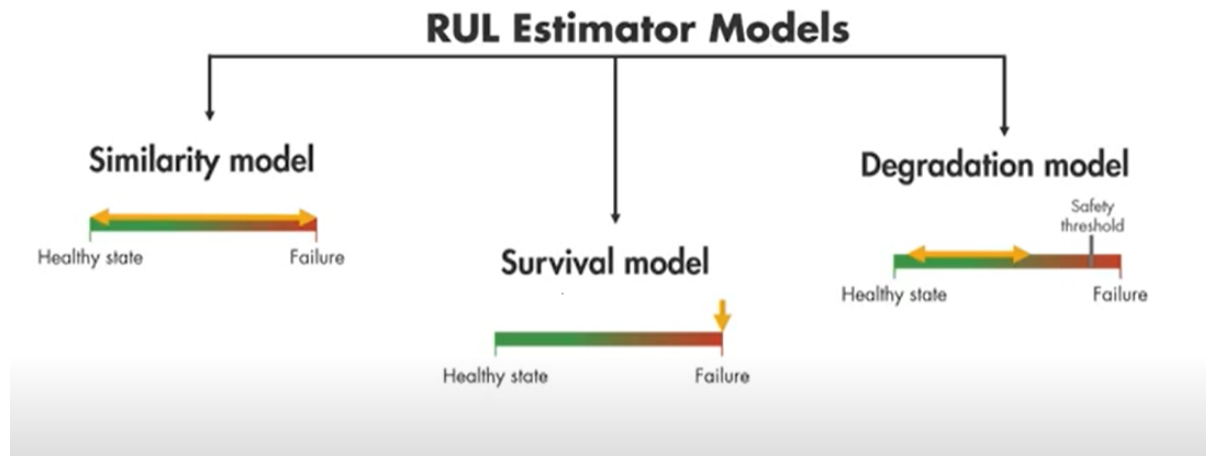
Les modèles de similarité sont des modèles qui estiment la RUL d'un objet en comparant ses caractéristiques actuelles avec celles d'objets similaires qui ont déjà atteint leur fin de vie. Ces modèles sont basés sur l'hypothèse que la durée de vie des objets similaires est corrélée, ce qui permet d'extrapoler la RUL de l'objet en question. Les modèles de similarité sont particulièrement utiles lorsque les données de performance passées de l'objet sont limitées, mais qu'il existe des données sur des objets similaires.

Les modèles de survie sont des modèles qui estiment la RUL d'un objet en fonction de sa durée de vie attendue, en utilisant des données sur la survie des objets similaires. Ces modèles sont basés sur la théorie de la survie, qui étudie la probabilité qu'un objet tombe en panne à un moment donné en fonction de ses caractéristiques. Les modèles de survie sont particulièrement utiles lorsque les données de performance passées de l'objet sont disponibles et que la distribution de la durée de vie de l'objet est connue ou peut être estimée.

Les modèles de dégradation sont des modèles qui estiment la RUL d'un objet en fonction de sa dégradation mesurée au fil du temps. Ces modèles sont basés sur l'hypothèse que la dégradation de l'objet est corrélée à sa durée de vie restante. Les modèles de dégradation sont particulièrement utiles lorsque les données de performance passées de l'objet sont disponibles et que la dégradation de l'objet peut être mesurée de manière fiable c.-à-d. on connaît un seuil que l'indicateur de condition ne peut pas le dépasser .

Le choix du modèle à utiliser dépendra des données disponibles sur l'objet et de l'objectif de l'analyse de la RUL. Les modèles de similarité sont plus appropriés si on a des données qui varient entre l'état sain et défectueux. Les modèles de survie sont plus appropriés lorsque les données de performance passées sont disponibles à partir de moment de panes . Les modèles de dégradation sont plus appropriés lorsque les données de performance passées sont disponibles sur l'état sain et

on n'a pas des données sur l'état défectueux mais on connaît un seuil qu'il faut pas dépasser notre indicateur de conditions



Description de travail réalisé

Prétraitement des données:

Dans tous les projets de machine learning ou d'IA, les données doivent être nettoyées afin de les rendre compatibles avec le modèle d'entraînement. Les problèmes qui nécessitent une rectification par prétraitement peuvent inclure :

- Des échantillons manquants
- Une étiquette/format incorrecte ou manquante
- Des valeurs aberrantes
- Une mise à l'échelle

L'ensemble de données fourni par le client avait déjà été nettoyé, de sorte qu'aucun traitement n'était nécessaire. Le format de l'ensemble de données était une liste de tuples. La liste comportait 50 entrées, ce qui signifiait 50 jours de données, et le tuple avait une longueur de 2, représentant une entrée pour le signal de vibration et une entrée pour le tachymètre. Les deux entrées étaient des tableaux de longueur 585936 pour vibration, et 2446 pour tachymètre, car les mesures étaient échantillonnées à une fréquence de 97658 sps pendant 6 secondes.

Le seul traitement de données requis était pour le tachymètre. Le signal représentait le nombre de radians que la turbine avait tourné depuis le début de l'échantillonnage, comme on peut le voir sur la figure <>. Il apparaissait donc comme une ligne linéaire commençant à 0 chaque jour. Nous avons donc différencié le signal pour trouver l'accélération subie par les pales.

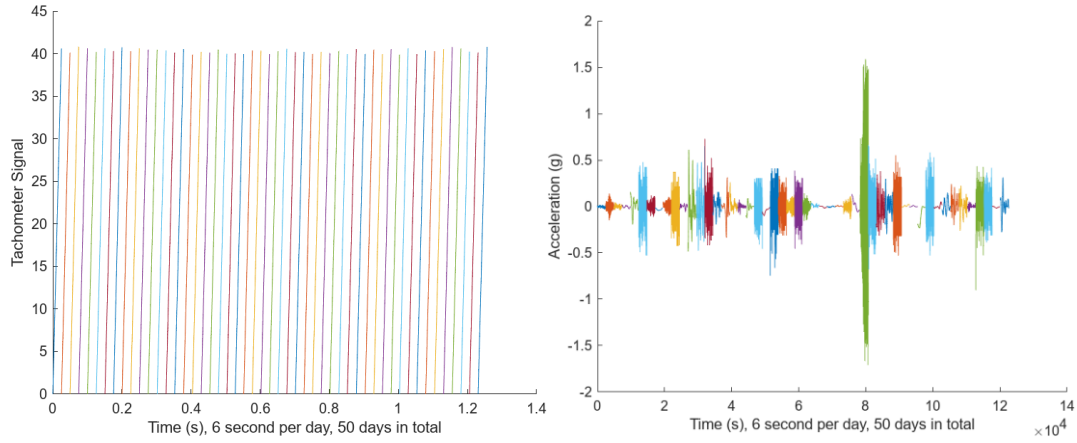


Figure 1a: tachometer signal and derived acceleration




Figure 1b: vibration signal

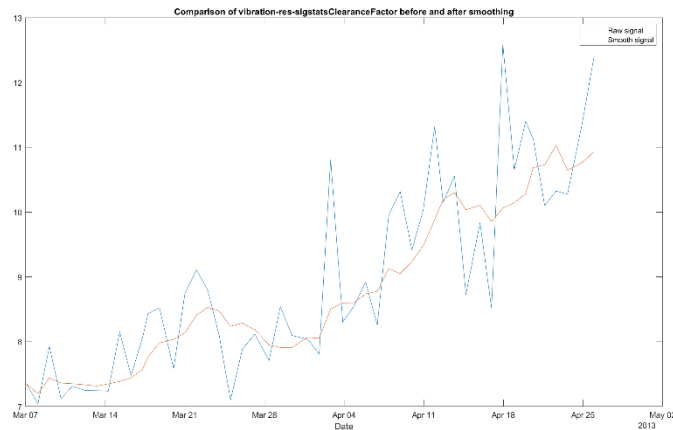
Feature extraction :

Pour l'extraction des caractéristiques, le Toolbox Diagnostic Feature Designer de Matlab a été utilisée. Ce Toolbox permet de saisir tous les échantillons dont nous disposons et de calculer les caractéristiques temporelles et fréquentielles. Il procède ensuite au classement des caractéristiques obtenues en fonction de la monotonie ou d'autres critères qui peuvent être choisis.

Lors d'une première approche, le module a été utilisé sans modification préalable des échantillons, ce qui a conduit à un classement des caractéristiques qui n'était pas le meilleur que nous pouvions obtenir car les échantillons contenaient du bruit à haute fréquence. Ceci est clairement visible avec l'expression de la monotonie :

$$monotonicity = \frac{1}{M} \sum_{j=1}^M \left| \sum_{k=1}^{N_j-1} \frac{sgn(x_j(k+1) - x_j(k))}{N_j - 1} \right|$$

Où M est le nombre de systèmes surveillés ($M = 1$), N_j est le nombre de mesures dans le $j^{ème}$ système et x_j est le vecteur de mesures des caractéristiques sur le $j^{ème}$ système. Il est facile de voir comment le bruit peut affecter la monotonie de chaque caractéristique, de sorte qu'une moyenne mobile prenant les cinq valeurs précédentes est introduite dans les caractéristiques extraites avant de les classer selon la monotonie.



Après le lissage des données, celles-ci sont classées en fonction de la monotonie, pour ensuite prendre les caractéristiques les plus importantes. Un seuil de 0,3 est choisi pour sélectionner ces caractéristiques. Une fois les principales caractéristiques choisies, une analyse PCA est envisagée pour réduire la dimensionnalité.

Une analyse de la quantité de caractéristiques prises en compte pour prédire le RUL devrait être effectuée. D'autres travaux concernant les caractéristiques du signal dans le domaine des fréquences restent à faire, car le module Matlab utilisé comporte moins de caractéristiques que les caractéristiques dans le domaine temporel (par exemple, spectral kurtosis).

Indicateur de Condition :

Nous disposons actuellement d'une collection de caractéristiques lissées présentant une bonne monotonie. Nous cherchons à utiliser ces caractéristiques pour entraîner un modèle de dégradation exponentielle, comme expliqué dans la section suivante, mais nous cherchons d'abord à réduire la dimensionnalité du problème. Si nous cherchons à former un modèle qui prédit la durée de vie restante de l'éolienne (un simple scalaire), le fait d'avoir une entrée de données de 15 à 40 caractéristiques rendra probablement la formation plus longue et augmentera le risque de overfitting. Nous cherchons donc à créer un indicateur d'état unique, qui est un représentant numérique de l'état de santé de l'éolienne.

Lorsque nous combinons plusieurs caractéristiques, nous devons d'abord les mettre toutes à la même échelle, afin d'éviter que les caractéristiques ayant une faible valeur numérique ne soient ignorées. Pour ce faire, nous mettons à l'échelle toutes les caractéristiques entre 0 et 1.

Nous cherchons ensuite à combiner les caractéristiques ensemble en une seule valeur. La façon la plus simple de le faire est d'attribuer un poids à chaque caractéristique, correspondant à son importance perçue, puis de faire une somme pondérée. La figure 3 montre l'indicateur de condition en vert, de 18 caractéristiques dérivées du signal de vibration, chacune avec un poids de 1/18. Ainsi, dans ce cas, c'est une simple moyenne.

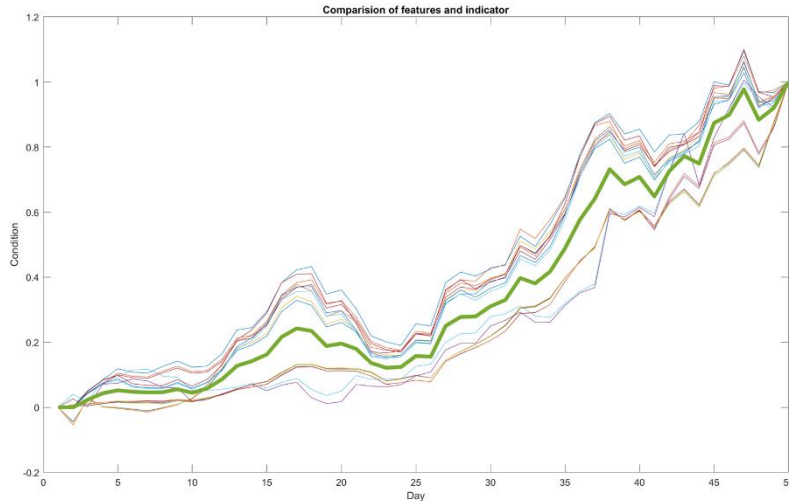


Figure 3: Condition Indicator calculated by a simple mean

Une moyenne n'est pas la meilleure façon de fusionner les données, une méthode que nous pourrions utiliser pour obtenir un indicateur plus précis serait l'analyse en composantes principales (PCA), qui cherche à projeter un ensemble de données de haute dimension dans un espace de dimension inférieure. Cependant, cette méthode n'a pas encore été implémentée dans notre code.

Modèle de Dégradation:

En raison de la limitation de notre ensemble de données, nous ne sommes pas en mesure d'utiliser des méthodes telles que celle du "plus proche voisin", qui compare le signal de vibration de l'éolienne à des signaux similaires provenant d'autres éoliennes, afin de tenter de prédire la progression future. Par conséquent, la seule méthode que nous pouvons utiliser est le modèle de dégradation exponentielle. Ce modèle postule qu'au fur et à mesure que la santé de l'éolienne se dégrade, le taux de dégradation augmente. L'utilisation de ce modèle se justifie de deux manières. La première est visuelle, nous pouvons voir dans la Figure <> que l'amplitude des vibrations n'augmente pas linéairement avec le temps, mais semble avoir une certaine augmentation exponentielle. La seconde provient d'une connaissance a priori du système, qui nous indique qu'au fur et à mesure que les roulements sont exposés à davantage de vibrations, ils sont susceptibles de s'endommager plus rapidement, ce qui entraîne une augmentation plus rapide des vibrations.

L'équation du modèle est la suivante:

$$Y(t) = \beta * e^{(-\alpha t)} + \epsilon(t)$$

- $Y(t)$ est le niveau de santé ou de dégradation de l'éolienne à l'instant (t)
- β est l'état de santé initial à $t = 0$
- α est le taux de dégradation de l'état de santé
- ϵ représente le bruit de mesure

Pour entraîner le modèle, nous lui donnons les valeurs de l'indicateur d'état pour chaque jour jusqu'à aujourd'hui, et la fonction matlab "exponentialDegradationModel" de la "Predictive Maintenance Toolbox" cherche à ajuster les paramètres de l'équation pour minimiser l'erreur. Nous disposons désormais d'une expression capable de prédire l'évolution de l'état de santé de l'éolienne

dans le futur. Pour prédire la RUL, nous devons savoir à quel état de santé la turbine se brisera. C'est là qu'il faut obtenir l'historique du parc de turbines ou une connaissance précise de la construction physique de la turbine. Comme nous ne disposons pas de ces informations dans l'ensemble de données actuel, nous supposons que notre turbine se casse le jour 50 (le dernier jour de l'ensemble de données), et nous prenons la valeur de l'indicateur d'état ce jour-là comme seuil de défaillance (la valeur = 18). Pour calculer le RUL, nous sous-intégrons donc cette valeur pour Y et calculons le t correspondant.

$$RUL = t^* - t_{\text{present}} \quad Y(t^*) = Y_{\text{threshold}}$$

Pour créer une prédiction dynamique de la RUL, il suffit de mettre à jour notre modèle avec les nouvelles données de vibration à chaque pas de temps, le modèle ajuste alors les paramètres de l'équation, et une nouvelle RUL est donnée. En règle générale, à mesure que la défaillance se rapproche, la prédiction RUL devient plus précise pour deux raisons. Premièrement, la prédiction est moins éloignée dans le temps, ce qui signifie que l'effet des paramètres incorrects est moindre, et deuxièmement, à mesure que l'état se détériore, alpha et bêta tendent à devenir plus significatifs par rapport au bruit du système.

Il est clair que ce modèle sera 'overfitted' à nos données, car nous utilisons en fait nos données d'entraînement pour valider le modèle (nous prenons le threshold de la même éolienne). Cependant, notre modèle pourrait être grandement amélioré en utilisant le même workflow avec même une petite amélioration, telle que la connaissance du threshold moyen de défaillance d'une centaine d'éoliennes différentes.

Résultats et prochaines étapes

Nous avons entraîné le modèle sur les 40 premiers jours de données, puis mis à jour le modèle avec les 10 derniers jours, en prédisant le RUL après chaque mise à jour. Au cours du processus de formation, nous avons reçu plusieurs avertissements, comme indiqué dans la figure 4. Le premier avertissement concerne le fait qu'il n'y a qu'un seul exemple d'entraînement, ce qui est difficile à rectifier car nous n'avons que l'historique d'une seule éolienne, mais nous pourrions essayer de simuler les données ou chercher des ensembles de données alternatifs en ligne à l'avenir. N'avoir qu'un seul exemple signifie que le modèle ne peut pas calculer dans quelle mesure la variation du signal est due au bruit des capteurs ou à l'état réel de la turbine qui varie, cela augmente également le risque de 'overfitting' comme mentionné précédemment. Le deuxième avertissement concerne l'incertitude des paramètres du modèle et leur grande variance, qui est également due au fait qu'il n'y a qu'un seul exemple. Cependant, nous pourrions essayer de résoudre ce problème en améliorant notre choix d'indicateur de condition. En combinant les caractéristiques dérivées du tachymètre dans l'indicateur et en utilisant l'PCA, nous pourrions peut-être lisser un peu plus notre indicateur, de sorte qu'il ressemble mieux à une fonction exponentielle. Les résultats de notre prédiction sont présentés dans la figure 5. Il est clairement médiocre, car il prédit souvent 0 jours restants, même lorsque notre indicateur est assez éloigné du seuil à ce jour. Notre travail pour l'avenir immédiat consiste à améliorer cette prédiction.

```
Warning: Ensemble only has one member. The parameter variances in the Prior are not changed.
> In predmaint.internal.rul/ExponentialDegradationRULEstimator/fit_ (line 529)
In rulModel/fit (line 131)
In degradation_model (line 5)
Warning: The estimated value of the slope parameter 'Theta' has a large variance. The direction of degradation growth is uncertain.
> In predmaint.internal.rul/ExponentialDegradationRULEstimator/fit_ (line 537)
In rulModel/fit (line 131)
In degradation_model (line 5)
```

Figure 4: Warnings given by matlab when training the model




Figure 5: RUL plot

Répartition des tâches

Analyse, extraction et choix de features - Diego

Réglage de l'indicateur de condition et mise en œuvre du modèle de dégradation - Ben

Matlab code – Diego and Ben

Bibliographie - Valentin, Ayoub, Mohammed